

Comparaison d'Algorithmes de Classification

Etude sur Iris Dataset

boutadghart chaymaa

1 Introduction

La classification est une tâche fondamentale en machine learning. Elle consiste à prédire une classe à partir de variables explicatives. Dans ce TP, nous utilisons le dataset Iris pour comparer différents modèles de classification et analyser leurs résultats.

2 Description du Dataset

Le dataset Iris contient 150 observations réparties en trois classes :

- Setosa
- Versicolor
- Virginica

Les variables explicatives sont :

- Sepal length
- Sepal width
- Petal length
- Petal width

La variable cible est le type de fleur.

3 Analyse Exploratoire des Données

3.1 Statistiques descriptives

Nous avons calculé les statistiques principales (moyenne, écart-type, min, max). Les variables présentent des échelles différentes.

3.2 Visualisation

- Histogrammes pour analyser la distribution
- Boxplots pour détecter les valeurs aberrantes
- Matrice de corrélation pour étudier les relations




FIGURE 1 – Histogrammes des variables

4 Prétraitement des Données

4.1 Valeurs manquantes

Aucune valeur manquante n'a été détectée.

4.2 Normalisation

Nous avons utilisé StandardScaler pour normaliser les données. Cette étape est importante pour les modèles basés sur la distance comme KNN et SVM.

4.3 Division des données

Les données ont été divisées en :

- 80% pour l'entraînement
- 20% pour le test

5 Modèles Utilisés

- Régression Logistique
- KNN (K-Nearest Neighbors)
- Arbre de Décision
- Random Forest
- SVM (Support Vector Machine)

6 Évaluation des Modèles

Les métriques utilisées sont :

- Accuracy
- Precision
- Recall

— F1-score

6.1 Matrice de confusion

La matrice de confusion permet d'évaluer les performances détaillées du modèle.




FIGURE 2 – Matrice de confusion

7 Résultats

Les résultats obtenus montrent que :

- Random Forest et SVM donnent les meilleures performances
- KNN s'améliore après normalisation
- Decision Tree peut surapprendre

8 Discussion

Le modèle Random Forest est le plus performant et le plus stable. Les modèles basés sur la distance sont sensibles à l'échelle des données, ce qui explique l'importance du scaling.

9 Conclusion

- Le prétraitement est essentiel
- Le choix du modèle influence fortement les résultats
- Random Forest offre un bon compromis entre performance et robustesse